## 1. Print Source Code

這是最基本的功能，將讀進來的 Source Code 一行一行的印出來，首先宣告以下的變數：

```
3   %{
4       #include <stdio.h>
5       #include <string.h>
6       #include <math.h>
7
8       int numL = 1;
9       char buf[1000];
10      int bufIndex = 0;
11
12      int tokenOn = 1;
13      int sourceOn = 1;
14  %}
```

numL 為目前的行數，buf 則是存放在該行的 code 等待印出，最後一個 bufIndex 則是記錄著目前這行 code 的長度。在我所做的 scanner 中，**每個 match 到 pattern 的字串都會被存在 buffer 之中**，以下提供一個例子：

```
57  "/*"    {
58          BEGIN(COMMENT);
59
60          strcpy(&(buf[bufIndex]), yytext);
61          bufIndex += yyleng;
62      }
```

這邊可以看到，只要 match 到”/*”這個 pattern，該字串就會被放到 buf 之中，而 bufIndex 也會更新，而其他的 pattern 也會有一樣的動作。**最後當遇到換行的時候，會將該行的 code 印出**：

```
189  \n  {
190
191          /* Check pragma */
192          if(sourceOn == 1)   printf("%d:%s\n",numL,buf);
193
194          numL++; /* Enter newline */
195
196          buf[0] = 0;  /* Clean Buffer */
197          bufIndex = 0;
198
199      }
```

將該行 code 印出以後，會增加 numL，代表進入下一行，並且將 buf[0]設為 null character，以防被其他 pattern 印出這行的 code，並重設 bufIndex 為 0。

## 2. Pragma Directives

為了控制是否印出 source code 或 token，首先宣告兩個變數：

```
3   %{
4       #include <stdio.h>
5       #include <string.h>
6       #include <math.h>
7
8       int numL = 1;
9       char buf[1000];
10      int bufIndex = 0;
11
12      int tokenOn = 1;
13      int sourceOn = 1;
14  %}
```

tokenOn 等於 1 時代表要印出 token，sourceOn 等於 1 時代表要印出 source code，而只要這兩個變數不是 1，則代表不需要印

出，因此在宣告時，預設都為 1 那就是預設 token 和 source code 都是要印出來的。而接下來**在每一個 pattern 中，都會檢查 tokenOn 或 sourceOn 的值，來決定是不是要印出資訊**，以下提供一個檢查 tokenOn 例子：

```
94   {KEY}    {
95            /* Check pragma */
96            if(tokenOn == 1)     printf("#key:%s\n",yytext);
```

以及換行要印出 source code 時，檢查 sourceOn：

```
189   \n  {
190
191           /* Check pragma */
192           if(sourceOn == 1)    printf("%d:%s\n",numL,buf);
```

**那麼如何在 input 中識別出 pragma directives 呢？**

首先我們先定義一些 pattern：

```
43   SPACE    [ \f\t\r\v]+
44
45   SOURCE_ON    #{SPACE}?"pragma"{SPACE}"source"{SPACE}"on"
46   SOURCE_OFF    #{SPACE}?"pragma"{SPACE}"source"{SPACE}"off"
47   TOKEN_ON     #{SPACE}?"pragma"{SPACE}"token"{SPACE}"on"
48   TOKEN_OFF    #{SPACE}?"pragma"{SPACE}"token"{SPACE}"off"
```

這樣一來，當我們在 input 中遇到符合這些 pattern 的 code 時：

```
52  {SOURCE_ON}     {   sourceOn = 1;   strcpy(&(buf[bufIndex]), yytext);   bufIndex += yyleng;}
53  {SOURCE_OFF}    {   sourceOn = 0;   strcpy(&(buf[bufIndex]), yytext);   bufIndex += yyleng;}
54  {TOKEN_ON}      {   tokenOn = 1;    strcpy(&(buf[bufIndex]), yytext);   bufIndex += yyleng;}
55  {TOKEN_OFF}     {   tokenOn = 0;    strcpy(&(buf[bufIndex]), yytext);   bufIndex += yyleng;}
```

我們就能更改 sourceOn 和 tokenOn 的值，以達到控制的目的。

## 3. Comment

遇到 comment 時，只要直接印出該行的 source code 就好，但因為有其他的 pattern 可能會不小心 match 到，因此我們需要**使用 exclusive start condition**，首先定義：

```
16   %x   COMMENT
```

有了 start condition 以後，當我們**遇到 comment 的開頭"/*"**時，便進入了 COMMENT 的 condition 之中：

```
57   "/*"      {
58             BEGIN(COMMENT);
59
60             strcpy(&(buf[bufIndex]), yytext);
61             bufIndex += yyleng;
62         }
```

在 condition 之中**遇到除了換行以外的字元**，我們就將它放到 buf 中等待印出：

```
81   <COMMENT>.  {
82           /* If use .*  then it will eat the ending of comment */
83
84           strcpy(&(buf[bufIndex]), yytext);
85           bufIndex += yyleng;
86       }
```

在 condition 之中**遇到換行字元**，將該行的 comment 印出，並增加記錄行數的 numL，重設 buf 和 bufIndex，繼續讀取 comment：

```
70   <COMMENT>\n {
71           /* Comment newline print it out */
72
73           /* Check pragma */
74           if(sourceOn == 1)   printf("%d:%s\n",numL,buf);
75
76           numL++; /* Enter newline */
77
78           buf[0] = 0;  /* Clean Buffer */
79           bufIndex = 0;
80       }
```

最後當**遇到 comment 結尾"*/"時**，我們就退出 condition，讓 scanner 去 match 其他的 pattern：

```
63   <COMMENT>"*/" {
64           /*  End of Comment  */
65           BEGIN(INITIAL);
66
67           strcpy(&(buf[bufIndex]), yytext);
68           bufIndex += yyleng;
69   }
```

最後還有另外一種單行的 **comment**：

```
88  "//".*  {
89          /* Single line comment , simply copy to buf, and wait for \n to handle*/
90          strcpy(&(buf[bufIndex]), yytext);
91          bufIndex += yyleng;
92      }
```

由”//”後面緊跟著除了換行以外的字元，將這些字串放入 buf 中等待遇到換行字元，遇到以後會直接印出。

## 4. Keyword

首先，我們先把所有的 **keyword** 收集起來定義到兩個別稱：

```
KEY    "void"|"int"|"double"|"bool"|"char"|"null"|"for"|"while"|"do"|"if"|"else"|"switch"|"return"
|"break"|"continue"|"const"|"true"|"false"|"struct"|"case"|"default"
```

以及所有的 stdio.h 裡的 function：

```
STDIO    "remove"|"rename"|"tmpfile"|"tmpnam"|"fclose"|"fflush"|"fopen"|"freopen"|"setbuf"|"setvbuf"
|"fprintf"|"fscanf"|"printf"|"scanf"|"sprintf"|"sscanf"|"vfprintf"|"vprintf"|"vsprintf"|"fgetc"|"fgets"
|"fputc"|"fputs"|"getc"|"getchar"|"gets"|"putc"|"putchar"|"puts"|"ungetc"|"fread"|"fwrite"|"fgetpos"
|"fseek"|"fsetpos"|"ftell"|"rewind"|"clearerr"|"feof"|"ferror"|"perror"
```

如此一來只要 input **match 到 KEY 和 STDIO 的字串，我們就可以直接輸出 token**，並把字串放入 buf 裡：

```
 94  {KEY}   {
 95          /* Check pragma */
 96          if(tokenOn == 1)    printf("#key:%s\n",yytext);
 97
 98          strcpy(&(buf[bufIndex]), yytext);
 99          bufIndex += yyleng;
100      }
```

```
102  {STDIO} {
103          /* Check pragma */
104          if(tokenOn == 1)    printf("#key:%s\n",yytext);
105
106          strcpy(&(buf[bufIndex]), yytext);
107          bufIndex += yyleng;
108      }
```

## 5. Identifiers

根據 C99 Standard 中的定義：

*identifier:*
*identifier-nondigit*
*identifier identifier-nondigit*
*identifier digit*

*identifier-nondigit:*
*nondigit*
*universal-character-name*
other implementation-defined characters

*nondigit:* one of
_ a b c d e f g h i j k l m
n o p q r s t u v w x y z
A B C D E F G H I J K L M
N O P Q R S T U V W X Y Z

由以上式子可以推出，**Identifier 是 nondigit 開頭，後面可以再接上 nondigit 或 digit**，因此我們直接定義 ID：

```
ID      [a-zA-Z_]+[a-zA-Z_0-9]*
```

並在遇到 ID 時，將 token 印出：

```
176   {ID}    {
177           /* Check pragma */
178           if(tokenOn == 1)    printf("#id:%s\n",yytext);
179
180           strcpy(&(buf[bufIndex]), yytext);
181           bufIndex += yyleng;
182       }
```

## 6. Operator

一樣的，我們將**所有 operator 收集起來，放到 OP 這個別稱中**：

```
OP      "+"|"-"|"*"|"/"|"%"|"++"|"--"|"<"|"<="|">"|">="|"=="|"!="|"="|"&&"|"||"|"!"|"&"
```

而 input 進來如果 **match 到 OP，就將 token 印出**：

```
140   {OP}    {
141           /* Check pragma */
142           if(tokenOn == 1)    printf("#op:%s\n",yytext);
143
144           strcpy(&(buf[bufIndex]), yytext);
145           bufIndex += yyleng;
146       }
```

## 7. Punctuation

如同 Operator，**收集所有的符號，放到 PUNC 這個別稱中**：

```
PUNC    ":"|";"|","|"."|"["|"]"|"("|")"|"{"|"}"
```

而 input 進來如果 **match 到 PUNC，就將 token 印出**：

```
132   {PUNC}  {
133           /* Check pragma */
134           if(tokenOn == 1)    printf("#punc:%s\n",yytext);
135
136           strcpy(&(buf[bufIndex]), yytext);
137           bufIndex += yyleng;
138       }
```

## 8. Integer Constant

根據 C99 Standard 中的定義：

*integer-constant:*

*decimal-constant integer-suffix*$_{opt}$

*octal-constant integer-suffix*$_{opt}$

*hexadecimal-constant integer-suffix*$_{opt}$

由於這次要求實作十進位，因此後面兩個不需考慮，而 **decimal-constant** 的定義如下：

*decimal-constant:*

*nonzero-digit*

*decimal-constant digit*

*nonzero-digit:* one of

**1 2 3 4 5 6 7 8 9**

而 **integer-suffix** 的定義如下：

*integer-suffix:*

*unsigned-suffix* *long-suffix*$_{opt}$
*unsigned-suffix* *long-long-suffix*
*long-suffix* *unsigned-suffix*$_{opt}$
*long-long-suffix* *unsigned-suffix*$_{opt}$

*unsigned-suffix:* one of

`u` `U`

*long-suffix:* one of

`l` `L`

*long-long-suffix:* one of

`ll` `LL`

這樣我們可以總結出，**整數常數是由非 0 的數字開頭，後面可以接上數字，最後接上一個 optional 的 suffix** 因此我們可以定義：

```
INT     ({DIGIT}|[1-9]{DIGIT}*){IS}?
```

```
L       (l|L|ll|LL)
U       (u|U)
IS      ({U}|{L}|{L}{U}|{U}{L})
```

IS 就是所有可能的 integer-suffix，DIGIT 則是 0~9 的數字，比較特別的是，**在 C99 中，0 是屬於八進位**，但由於我觀察 testcase 中，0 也算是這次的範圍，因此**特別把 0 包括進去。**

而 input 進來如果 **match 到 INT，就將 token 印出**：

```
108   {INT}   {
109           /* Check pragma */
110           if(tokenOn == 1)    printf("#integer:%s\n",yytext);
111
112           strcpy(&(buf[bufIndex]), yytext);
113           bufIndex += yyleng;
114       }
```

## 9. Floating Point Constant

在 C99 Standard 中，Scientific notation 是歸類在 Floating point constant 之中的，但我打算將 scientific notation 放在下一個再來介紹，這邊只說明非 Scientific notation 的 Floating point constant，首先在 Standard 中：

*decimal-floating-constant:*
*fractional-constant exponent-part*$_{opt}$ *floating-suffix*$_{opt}$
*digit-sequence exponent-part floating-suffix*$_{opt}$

去除掉 Scientific notation，我們可以得到 Floating point constant：

***fractional-constant + floating-suffux(opt)***

我們再往 fractional-constant 和 suffix 的定義去看

*fractional-constant:*
*digit-sequence*$_{opt}$ . *digit-sequence*
*digit-sequence* .

*floating-suffix:* one of
**f l F L**

digit-seuence 是由數個 0~9 的數字所組成的數字串，照著以上這些定義，我們可以做出以下的 pattern：

```
18  DIGIT     [0-9]
19  DIGIT_SEQ  {DIGIT}+
20  FRAC     ({DIGIT_SEQ}?"."{DIGIT_SEQ})|({DIGIT_SEQ}".")
21  FS       (f|F|l|L)
22
23  DOUBLE   {FRAC}{FS}?
```

FRAC 就是 fractional-constant，FS 就是 floating-suffix。

而 input 進來如果 **match 到 DOUBLE，就將 token 印出**：

```
117  {DOUBLE} {
118          /* Check pragma */
119          if(tokenOn == 1)    printf("#double:%s\n",yytext);
120
121          strcpy(&(buf[bufIndex]), yytext);
122          bufIndex += yyleng;
123      }
```

額外實作內容的 testcase(advance.c)與結果圖會附在最後一部分。

## 10. Scientific notation

延續剛剛提到的 C99 Standard，扣除掉已經處理的部份，我們可以知道 Scientific notation 的定義如下：

**fractional-constant + exponent part + floating-suffix(opt)**

或是

**digit-sequence + exponent part + floating-suffix(opt)**

而 exponent part 的定義：

*exponent-part:*

**e** $sign_{opt}$ *digit-sequence*

**E** $sign_{opt}$ *digit-sequence*

sign 就是+和-，有了這些資訊，我們就可以定義出：

```
E       [Ee][+-]?{DIGIT_SEQ}
SCI     ({FRAC}|{DIGIT_SEQ}){E}{FS}?
```

E 就是 exponent part。

而 input 進來如果 **match 到 SCI，就將 token 印出**：

```
125   {SCI}   {
126           /* Check pragma */
127           if(tokenOn == 1)    printf("#sci:%s\n",yytext);
128
129           strcpy(&(buf[bufIndex]), yytext);
130           bufIndex += yyleng;
131       }
```

額外實作內容的 testcase(advance.c)與結果圖會附在最後一部分。

## 11. String & Char Constant

String 的定義如下：

```
STR     L?\"(\\(n|t)|[^"\\\n])*\"
```

String 是由**兩個雙引號包起來的字串，而雙引號中間的多個字元可以是非'/'，非雙引號，非換行字元的其他所有字元**，由於這次也支援控制字元\n 和\t，**因此中間也可以是"\n"或"\t"，在這邊的\n 和\t 是兩個字元(\和 n)**，而不是單個字元(換行字元\n)。另外**額外支援 C99 的 wide string literal**，因此 pattern 前面有一個 optional 的 L。

Char 的定義如下：

```
CHAR    L?'([^'\\\n]|\\(n|t))'
```

Char 是由**兩個單引號包起來的一個字元**，這個字元**可以是非'/'，非雙引號，非換行字元的其他所有字元**，由於這次也支援控制字

元\n 和\t，**因此中間也可以是"\n"或"\t"，在這邊的\n 和\t 是兩個字元(\和 n)**，而不是單個字元(換行字元\n)。另外**額外支援 C99 的 wide character constant**，因此 pattern 前面有一個 optional 的 L。

定義完以上的 pattern 後，input 進來如果 **match 到 STR 或 CHAR，就將 token 印出，要注意的是 string 不會印出雙引號和 prefix，而 Char 則相反，會完整印出單引號和 prefix**：

```
163  {STR}   {
164          /* Extract String */
165          char str[1000];
166          if(yytext[0] == 'L')
167          {
168              strcpy(str,yytext+2); /* The first " is gone */
169              str[yyleng-3] = 0; /* The last " is gone */
170          }
171          else
172          {
173              strcpy(str,yytext+1);
174              str[yyleng-2] = 0; /* The last " is gone */
175          }
176
177
178          /* Error Detect? */
179
180          /* Check pragma */
181          if(tokenOn == 1)    printf("#string:%s\n",str);
182
183          strcpy(&(buf[bufIndex]), yytext);
184          bufIndex += yyleng;
185      }
```

```
151  {CHAR}  {
152
153           /* Error Detect? */
154
155           /* Check pragma */
156           if(tokenOn == 1)    printf("#char:%s\n",yytext);
157
158           strcpy(&(buf[bufIndex]), yytext);
159           bufIndex += yyleng;
160       }
```

額外實作內容的 testcase(advance.c)與結果圖會附在最後一部分。

## 12. Error Handling

我的作法是將所有合法的 pattern 都完整定義出來，如果 scanner 讀到的 input **沒辦法 match 到上面講的所有 pattern(前面 1~11)，那麼就是不合法的 input**，因此我將最後一個 rule(放在 Rule section 最下面)訂為：

```
200   .   {
201           fprintf(stderr, "Error at line %d: %s\n", numL, yytext); exit(1);
202
203           strcpy(&(buf[bufIndex]), yytext);
204           bufIndex += yyleng;
205       }
```

“.”代表著除了換行字元以外的所有字元，**因此如果沒有 match 到前面的 rule，就會執行 fprintf 印出錯誤資訊，並執行 exit(1)**，scanner 就會結束。

## 13. Space

由於前面沒有定義到 Space 的 pattern，**因此我們必須在明確訂出 Space 的規則，否則 scanner 會將 Space 視為不合法的 input**，而進行 error handling，因此我們定義：

```
SPACE    [ \f\t\r\v]+
```

Space 只有可能由這些字元所構成，而 input match 到 SPACE 時，我們就將它放入 buf，等待印出。

```
183   {SPACE}    {
184             strcpy(&(buf[bufIndex]), yytext);
185             bufIndex += yyleng;
186         }
```

## 14. Advance Part Result

Wide string literal 和 Wide character constant：

```
1  /* String and Char */
2  L"ABCD"
3  L'A'
```

```
1  1:/* String and Char */
2  #string:ABCD
3  2:L"ABCD"
4  #char:L'A'
5  3:L'A'
```

Floating point constant suffix 和支援 C99 定義的格式：

```
5  /* Floating */
6  1234.
7  01234.
8  01234.01234
9  .1234
10
11 /* Floating suffix */
12 1234.L
13 1234.l
14 1234.F
15 1234.f
```

```
5:/* Floating */
#double:1234.
6:1234.
#double:01234.
7:01234.
#double:01234.01234
8:01234.01234
#double:.1234
9:.1234
```

```
11:/* Floating suffix */
#double:1234.L
12:1234.L
#double:1234.l
13:1234.l
#double:1234.F
14:1234.F
#double:1234.f
15:1234.f
```

Scientific notation suffix 和支援 C99 定義的格式：

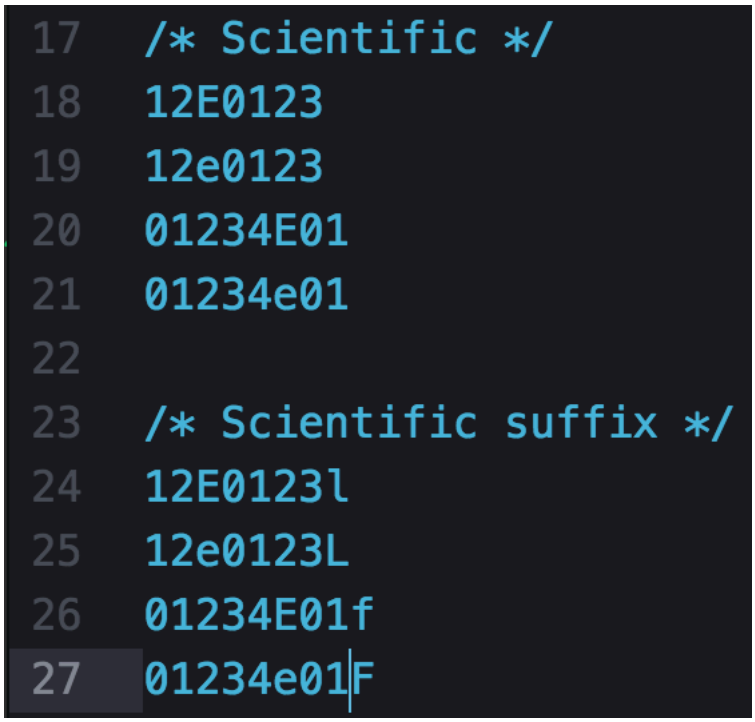

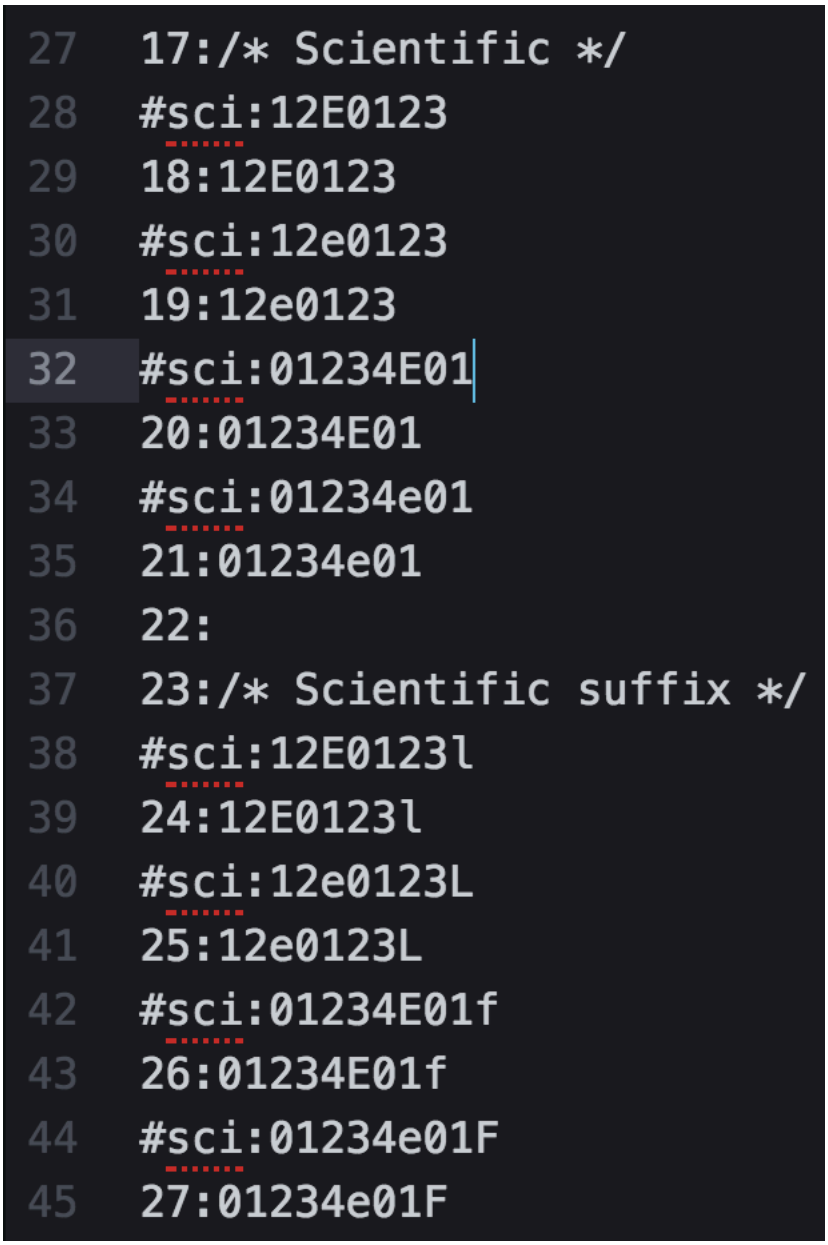


Integer constant suffix：

```
29  /* Integer suffix */
30  1234u
31  1234l
32  1234ll
33  1234LL
34  1234L
35  1234U
36
37  1234uLL
38  1234uL
39  1234ul
40  1234ull
41  1234ULL
42  1234UL
43  1234Ul
44  1234Ull
```

```
29:/* Integer suffix */
#integer:1234u
30:1234u
#integer:1234l
31:1234l
#integer:1234ll
32:1234ll
#integer:1234LL
33:1234LL
#integer:1234L
34:1234L
#integer:1234U
35:1234U
36:
```

```
#integer:1234uLL
37:1234uLL
#integer:1234uL
38:1234uL
#integer:1234ul
39:1234ul
#integer:1234ull
40:1234ull
#integer:1234ULL
41:1234ULL
#integer:1234UL
42:1234UL
#integer:1234Ul
43:1234Ul
#integer:1234Ull
44:1234Ull
45:
```

```
45
46  1234lu
47  1234llu
48  1234Lu
49  1234LLu
50
51  1234lU
52  1234llU
53  1234LU
54  1234LLU
```

```
#integer:1234lu
46:1234lu
#integer:1234llu
47:1234llu
#integer:1234Lu
48:1234Lu
#integer:1234LLu
49:1234LLu
50:
#integer:1234lU
51:1234lU
#integer:1234llU
52:1234llU
#integer:1234LU
53:1234LU
#integer:1234LLU
54:1234LLU
```